※ 공부 참고용 기출 선지 정리본입니다! 질문 있으시면 DM으로 연락주세요!

뇽's 아카이브 ADsP 오답 정리본

<1과목>

데이터 이해

DIKW 피라미드 파트

지혜 : 지혜는 개인에게 가장 깊이 내재된 상태로, 타인과 쉽게 공유하기 어렵다

데이터 유형

반정형 데이터는 가공을 통해 정형 데이터로 변환 가능한 데이터이다

사물인터넷 IOT 센서에서 수집되는 로그데이터도 반정형 데이터이다

형식지

공통화: 개인의 경험이나 지식이 공유되어 다른 사람의 암묵지로 전이되는 과정

표출화: 암묵지를 전달 가능한 형식지로 변환하는 과정

연결화: 개인이 보유한 경험과 외부의 지식을 연결하는 과정

내면화: 학습이나 행동을 통해 형식지를 개인의 암묵지로 체화

분석방법론 생성과정 순환 (2과목 미리 선행)

암묵지 > (형식화) > 형식지 > (체계화) > 방법론 > (내재화) > 암묵지

@imyngs - 무단 배포와 상업적 이용 금지입니다! 그 정도가 아니거든요... | © 2026

데이터베이스의 정의와 특징

데이터베이스는 2차원 구조 외의 다양한 형태의 데이터 구조를 저장한다

데이터베이스는 데이터를 체계적으로 저장 관리하도록 구조화한 집합

정보이용성: 일반적으로 정보의 접근성과 활용가능성을 의미한다

기계가독성: 정보를 일정한 형식에 따라 컴퓨터 등 정보처리 장치가 읽고 쓰는 것을 의미한다

검색가능성: 원하는 정보를 다양한 방법으로 검색할 수 있음을 의미한다

원격조작성: 네트워크 환경을 통해 원거리에서도 데이터를 접근하고 활용 가능(원격이용)

기업 내부 활용 데이터베이스

OLPT: 수시로 데이터를 갱신한다

OLAP: 데이터를 조회한다 , 대화식 처리분석 시스템이다

ERP: 경영자원 통합관리, 업무의 효율성 높임

데이터 모델링은 데이터 포인트 간의 연결 및 관계를 이해하기 위해 시각화로 표현하는 일련의 프로세스를 의미한다

+기업내부데이터베이스 활용과 먼 것

ITS: 지능형 교통 체계

NEIS: 사회기반구조 데이터베이스

@imyngs - 무단 배포와 상업적 이용 금지입니다! 그 정도가 아니거든요... | © 2026

데이터 웨어하우스

데이터 웨어하우스에서 데이터를 저장할 때 추출, 변환, 로드를 정해진 규약에 따라 수행한다

일반적으로 데이터 마트는 전사적 차원보다는 인사, 재무, 운영 등의 특정조직의 업무 분야에 맞춰 설계된다.

데이터 웨어하우스는 각종 매체에 흩어진 전사데이터를 하나의 공간으로 모아놓은 데이터 집합체로 클라우드 환경 뿐만 아니라 기업의 환경에 맞춰 그 위치 설정 가능하다 (즉, 반드시 클라우드 환경 아니다)

데이터 웨어하우스와 데이터 마트는 반드시 데이터 관리 시스템으로 관리되어야한다

↳ 반드시 그럴 필요는 없다

인터넷에 연결된 서로 다른 기기들이 사람의 개입 없이 상호 간의 데이터를 주고받아 처리하는 기술은 사물인터넷(IOT) 기술이라고 한다

빅데이터의 이해

클라우드 컴퓨팅은 데이터 분석 비용 문제를 해결해준다

데이터 단위

1024TB = 1PB　　1024PB = EB

1024EB = ZB　　1024ZB = YB

@imyngs - 무단 배포와 상업적 이용 금지입니다! 그 정도가 아니거든요... | © 2026

빅데이터의 가치와 영향

데이터 가용성은 빅데이터의 본질적인 특성이 아니다

빅데이터의 최종 목표는 새로운 가치의 창출

<빅데이터의 효능>

고객세분화로 맞춤서비스 제공

기업의 혁신제고

정부 미래 대응정책

알고리즘을 활용한 의사결정 및 보조

산업 전체의 생산성 향상

빅데이터는 개인의 목적에 따라 활용이 확산되어 다양한 영역에서 활용된다

↳사물인터넷 발달에는 기여하지 않음(> 데이터화가 기여함)

빅데이터의 분석 기법

회귀분석: 수치형 (~에 따른 ~의 변화)

분류분석: 결과값이 범주형 (유형 : 고객이탈여부, 질병여부, 등급판정)

연관규칙: 상관관계 (IF~THEN)

유전자알고리즘: 최적화

감정분석: 댓글같은 텍스트를 통해 긍정 부정 여부 판별

소셜 네트워크 분석: 특정 두 인물간의 친밀도를 계산

텍스트 마이닝: 영화 리뷰를 통해 영화에 점수 부여

@imyngs - 무단 배포와 상업적 이용 금지입니다! 그 정도가 아니거든요... | © 2026

※ 공부 참고용 기출 선지 정리본입니다! 질문 있으시면 DM으로 연락주세요!

데이터 3법

개인정보보호법에서 개인별 행동 예측 알고리즘 소유권을 각 개인에게 제공한다

↳ 오답입니다. 각 개인에게 제공 안함

개인정보 비식별화

가명처리: 개인정보를 다른 정보로 대체해 직접적인 식별은 어렵게 하지만, 추가정보를 결합하면 재식별 가능한 상태로 만드는 방식

총계처리: 전체 데이터의 총합 또는 평균으로 정보를 제공

데이터 범주화: 특정 범위로 일반화, 특정 값이 아닌 범위를 제공

데이터 마스킹: 데이터를 삭제하는 것이 아닌, 식별할 수 없게 다른 값으로 가리는 기법

빅데이터의 분석

데이터 분석은 객관적 수치를 기반으로 수행되지만, 분석 목적 설정과 결과 해석 단계에서는 분석가의 주관이 개입될 수 있다

데이터 분석가는 분석 업무와 조직관리를 동시에 수행해서는 안 된다는 규정은 없다

데이터 사이언스 핵심 구성요소

언어적 요소, 네트워크 구축은 해당 안됨

데이터 사이언티스트의 필요역량

통찰력 있는 분석에 연구윤리는 연관 없음

네트워크 최적화 능력은 필요역량이 아니다

고객과의 공감능력은 필요역량이다

@imyngs - 무단 배포와 상업적 이용 금지입니다! 그 정도가 아니거든요... | © 2026

<2과목>

데이터 분석 기획의 이해

데이터 분석 도입은 복잡하고 반복적인 과정이 많아 핵심분석이 아닌 상태에서 여러 프로젝트를 동시에 수행하면 자원과 인력이 분산되어 오히려 전체 품질 효율성이 떨어짐

↳ 그래서 적절하지 않음

무엇을 어떻게 분석할 것인지 질문 형식으로 수행, 데이터에 대한 이해요구, 자동화적 프로세스 내재화

비즈니스 모델 캔버스

고객 관계, 채널, 핵심자원 > 혁신은 포함안됨

분석 기획 시 고려사항

최신분석방법모형은 해당 안됨

↳무조건 최신기법만 사용하는건 항상 최적의 선택이 아니므로 기획단계에서 부적절하다

분석수행에 필요한 자원, 인력, 시간, 비용 등 자원의 현실적 제약을 고려해야한다

일관성과 신뢰성의 안전성 확보

쉽게 전달 가능하고 활용 가능한 결과 설명용이성

리스크 비용은 고려하지 않는다

데이터분석프로세스의 데이터탐색 단계의 주요 목적

초기데이터를 이해하고 분석방향을 구체화하는 과정, 유연한 가설과 분석 아이디어 확장

분석문제의 세부전략과 절차를 체계적으로 설계하는 계획 수립은 해당안됨

@imyngs - 무단 배포와 상업적 이용 금지입니다! 그 정도가 아니거든요... | © 2026

CRISP-DM 분석 방법론

피드백과 반복이 가능한 계층적 프로세스 모델 기반

업무이해: 데이터 마이닝 목표설정도 포함

데이터 이해: 데이터 탐색도 포함

모델링: 모델링 과정에서 모델 작성 및 평가함

빅데이터 분석 방법론

데이터 준비 ~ 데이터 분석 단계에서 서로 피드백 받을 수 있다

데이터 준비: 데이터 수집 및 정합성 점검 과정에서 정당성 검정도 수행

데이터 분석: 탐색적 분석 단계에서 다양한 관점으로 데이터 분포 특성 확인, 시각화를 통해 숨겨진 패턴 및 이상 값을 파악하는 업무를 진행한다

회피: 위험요인 자체를 제거

전이: 위험을 다른 주체에게 이전

완화: 위험의 영향을 줄임

수용: 위험을 받아들이고 대비

분석과제 정의서는 소스데이터, 분석방법, 데이터 입수, 분석난이도, 분석데이터의 구조, 오픈데이터 등 다양한 범위를 고려한다

@imyngs - 무단 배포와 상업적 이용 금지입니다! 그 정도가 아니거든요... | © 2026

분석 과제 발굴

기업 내부 데이터만을 분석에 활용(X)

↳ 통찰과 예측력 떨어질 수 있어서 안됨

분석 방법은 과제 목적과 문제 정의에 부합하도록 작성

분석과제 중심 데이터 분석에선 반복된 평가 검증으로 점진적 정확도 높이고, 과제간의 선후 관계 파악, 데이터의 정확성 정합도 확보, 적합한 분석방법론 고려해야함

분석과제 정의서에는 해결하고자 하는 문제를 구체적으로 정의, 분석결과에 대한 평가 및 검증 기준을 제시

하향식 상향식 접근 방법

하향식 접근법 수행단계

↳ 최적화 > 해결책

상향식 접근법 수행단계

↳ 발견 > 통찰

상향식 분석이라도 일반적으로 분석기획이 선행된다

빠르게 변화하는 현대사회에선 상향식 접근법의 활용이 증가한다

지도학습: 정답 O

비지도학습: 정답X

@imyngs - 무단 배포와 상업적 이용 금지입니다! 그 정도가 아니거든요... | © 2026

분석 프로젝트 관리 방안

데이터분석프로젝트 "품질관리"

품질보증 활동은 프로젝트 전 과정에 걸쳐서 지속적으로 수행된다

품질관리 결과는 산출물이 품질기준을 충족하는지를 확인하는 활동으로

프로젝트 조기 종료를 위한 기준 X

품질관리는 프로젝트 조직의 표준 절차와 내부 품질관리 체계에 따라 수행되는 것이 일반적이고 외부기업과의 협력이 필수적이진 않다

품질관리는 품질검토와 품질보증 활동으로 구분되어 수행

분석과정에서 고려할 5요소에서 활용도 측면에선 정확도, 안전성 측면에선 정밀도

정확도: 모델과 실제 값 간의 차이가 적은 정도

정밀도: 반복 수행 시 모델 예측 값의 편차 수준

분석 마스터 플랜

ISP는 정보 기술과 정보 시스템을 조직의 전략적 목표달성에 효과적으로 활용하기 위한 중장기 계획 수립이다

조직 내부와 외부 환경을 종합적으로 분석

현재문제점을 파악하고 개선기회를 도출

조직의 전략적 목표와 정보기술의 연계방안 수입

정보 시스템 구축의 우선순위를 결정

중장기 정보화 마스터 플랜을 수립

기술적용수준은 세부요소로 우선순위 선정 기준 X

실행용이성은 우선순위 요소

@imyngs - 무단 배포와 상업적 이용 금지입니다! 그 정도가 아니거든요... | © 2026

데이터 분석 프로젝트의 우선순위 선정 기준

시급성은 전략적 중요도, KPI에 미치는 영향도, 비즈니스 긴급성

난이도 관점에 기업의 분석역량, 데이터 성숙도, 인프라수준도 포함

시급성과 난이도가 모두 높은 과제는 내부의 의사결정에 의해 우선순위 조정 가능

분석마스터플랜 수립시 적용 범위 및 방식에 대한 고려요소

업무 내재화 적용수준, 분석 데이터 적용수준, 기술 적용 수준

분석우선순위를 정할 때 가장 우선적으로 수행해야 하는 과제는 시급성 높고 난이도 낮은 과제 (바로 적용 가능)

분석우선순위는 일반적으로 비즈니스적 시급성과 기술적 난이도를 기준으로 결정

데이터 양과 분석 범위 조정은 수행의 난이도 조절은 가능하나, 시급성을 변화시키는 요소는 아니다

분석적용 비용과 분석수준은 영향을 미치는 요소이며 시급성에 영향을 주는 요소는 아니다

새로운 기술이나 인프라의 도입여부는 분석수행과제 구현의 난이도에 영향이 있다

↳ 난이도 조절 가능

데이터 분석 수준 진단

분석준비도에서 성과에 대한 진단은 핵심진단 영역 아니다

분석성숙도는 기업의 분석 역량과 분석 결과 활용 수준을 평가하는 것을 의미한다

~~분석성숙도는 인사이트 도출을 위해 유사 업종이나 경쟁상대와의 비교활동을 포함한다~~

↳ (오답)

@imyngs - 무단 배포와 상업적 이용 금지입니다! 그 정도가 아니거든요... | © 2026

분석성숙도 진단은 IT 인프라, 비즈니스 연계성, 조직문화 및 인력 역량 등이 평가 대상

↳ 비용, 서비스부분, 문화 > 다 해당안됨

능력 성숙도 통합모델 CMMI (5단계 구성)

1단계: 개인역량이 프로젝트 성공여부 나누는 요인으로 프로젝트 개발프로세스 거의없다

2단계: 일정, 비용 같은 프로세스 중심으로 약간의 개발프로세스 하에 통제

3단계: 2단계에서 존재하지 않는 조직을 관리하기 위한 프로세스가 존재하는 상태

4단계: 체계적인 관리하에 프로젝트 및 산출물 등에 대한 정량적 측정 가능 상태

5단계: 조직적으로 최적화된 프로세스 보유하고 지속적인 개선을 목표로 하는 상태

분석 수준 결과 진단

분석 과제의 우선 순위를 정할 때 가장 우선적으로 수행해야 하는 과제는 시급성이 높고 난이도 낮은 과제 (즉시 적용 가능)

준비형: 준비도 성숙도 모두 낮음

정착형: 준비도는 낮지만 성숙도는 높음

도입형: 준비도는 높지만 성숙도는 낮음

빅데이터 거버넌스

데이터 거버넌스 체계순서:

데이터 표준화> 데이터 관리체계> 데이터 저장소관리> 표준화 활동

데이터 유지보수 비용관리는 데이터 거버넌스 관리 범주에 해당 안됨

@imyngs - 무단 배포와 상업적 이용 금지입니다! 그 정도가 아니거든요... | © 2026

데이터 표준화: 표준용어 설정, 데이터 사전 구축, 명명규칙 설립

데이터관리 체계: 생명주기 관리방안, 사전역할평가 수행

표준화 활동: 표준 준수여부 점검 및 모니터링 수행

분석 지원 인프라 방안 수립

컴퓨터 시스템: 운영체제, 하드웨어 는 광의&협의에 해당 안됨

조직 및 인력방안 수립

분석 조직은 업무와 최종의사결정을 수행 안함

집중구조: 중복 업무(현업부서와 이중화 이원화 가능성 높은 단점) 가능성 존재

↳ 분석인력 중앙조직에 집중, 우선순위 관리 수행

기능구조: 전사적 관점의 통합적 분석결과 도출 어려움

분산구조: 현업 부서의 요구사항을 빠르게 파악하고 분석결과를 실무에 신속히 적용가능

↳ 전사적 관점에서 우선순위 선점가능

@imyngs - 무단 배포와 상업적 이용 금지입니다! 그 정도가 아니거든요... | © 2026

※ 공부 참고용 기출 선지 정리본입니다! 질문 있으시면 DM으로 연락주세요!

<3과목> 진짜 중요해요 특히 인공지능은 필수로 참고해주세요

데이터 분석

데이터 전처리에선 이상치 및 결측값 제거, 오버샘플링 및 언더샘플링, 파생변수 및 요약변수 생성

검증용 데이터를 활용한 파라미터 조정은 전처리 이후 모델링 단계에서 수행하는 작업

스태밍: 단어의 어원을 찾는 작업

웹크롤링: 데이터수집 위해 웹페이지의 구조를 분석헤 자동으로 데이터를 수집하는 방법

홀드아웃: 두 개의 데이터 셋으로 데이터를 분할하는 방법, 하나는 모형 학습 및 구축을 위한 훈련용 자료, 다른 하나는 성과평가를 위한 검증용 자료

요약변수: 요약해서 통계를 낸다

결측값 처리

결측치 제거의 목적은 소실을 감수하고 정제하는 목적

결측값 대치하는 이유는 표본수가 지나치게 줄어드는 것을 방지

완전대치는 대량의 데이터 손실발생 가능(결측값 많은 경우)

단순대치는 결측값 수 적을수록 효율적, 결측값 수 많으면 제거되는 데이터 많아 데이터 손실 가능성 커짐

조건부 평균대치법은 비조건부 평균대치법보다 좀 더 신뢰성 높은 값으로 결측값 대치

결측치를 단순히 제거하면 표본이 줄어들어 오히려 분석력이 떨어질 수 있고, 다양한 방법으로 결측값을 대체하면 데이터 손실 없이 분석에 활용할 수 있어 정확도 향상에 기여할 수 있다

@imyngs - 무단 배포와 상업적 이용 금지입니다! 그 정도가 아니거든요... | © 2026

이상값 검색

이상값을 식별하기 위해서는 충분한 양이 필요하다

ESD는 단일변수에 대한 이상값 파악에 유용하다

사분위수: 개수 평균값은 알 수 없다, 평균값 표현 없기에 꼬리 표현 불가능

IQR: 중간 50%에 해당되는 데이터의 흩어짐 정도

통계 분석

정보량이 많은 척도 비율> 등간> 서열> 명목

서열척도는 순서존재, 간격은 존재안함

질적척도(명목형)

비계량적 (명목척도, 순서척도(서열척도))

순서척도(서열척도)>스피어만

양적척도(수치형)

계량적 (등간척도(구간척도), 비율척도)

@imyngs

@imyngs - 무단 배포와 상업적 이용 금지입니다! 그 정도가 아니거든요... | © 2026

기초 통계량

비표본오차는 표본의 수가 많아질수록 증가

<변수가공>

변수를 범주화하여 나타낼 때 범주의 수가 적을수록 정확도가 올라간다

연속형 변수가 비효율적인 경우 범주형으로 변환하여 활용한다

총계, 평균과 같은 기초 통계량을 활용해 요약변수를 생성해 활용

주성분 분석을 통해 파생변수 생성가능

신뢰도 값이 커질수록 구간추청의 길이는 넓어진다

편향커지면 분산 작아지고, 분산작아지면 편향 커진다

분산이 크다는건 반복적으로 예측을 수행할 때 예측값의 차이가 큼을 의미

편향과 분산이 모두 최소가 되는 것이 가장 이상적인 모형

공분산은 단위 영향을 받지만, 상관계수는 단위 영향 안받음

공분산의 단위는 두 척도 단위의 곱이다

공분산과 상관계수의 부호는 항상 같다

원변수의 단위가 달라지면 공분산의 단위도 달라진다

상관계수는 두변수의 독립여부와 아무런 관계없음

상관계수는 두변의 공분산을 각각의 표준편차로 나눈 값

상관계수가 1일땐 강한 양의 상관관계

상관계수가 -1일땐 강한 음의 상관관계

상관계수가 0일땐 상관관계가 없거나 약함

@imyngs - 무단 배포와 상업적 이용 금지입니다! 그 정도가 아니거든요... | © 2026

상관계수는 단위 없고, 두변수의 스케일이나 단위의 영향 안받음

첨도와 왜도

중앙값은 이상치에 영향 적게 받음

이상치에 영향 많이 받는건 산술평균

표본추출 방법

계통 추출법: 무작위 아님

확률분포

교차분석(카이제곱 검정)은 명목척도나 서열척도 같은 범주형 변수 간의 독립성 또는 연관성을 분석하기 위해 사용

연속형 수치 데이터를 그대로 적용 불가, 필요한 경우 구간화 과정을 거쳐 범주형 변수로 변환한 뒤 분석 수행

1. 특정 범주에 대한 기대도수와 관찰도수의 차이를 이용해 분석

2. 교차분석은 교차표를 이용하여 두 변수간의 독립성을 검정

3. 기대도수가 5 미만인 셀의 비율이 20%를 초과하면 카이제곱분포에 근사하기 어려움으로(신뢰성 낮아짐) 표본 크기를 늘리거나 변수의 범주를 통합하는 방법 사용

4. 범주형 변수가 ~~아니어도~~ 교차분석 사용가능 은 <오답>

중심극한정리

모집단이 비대칭인 경우에도 중심극한정리를 통해 표본평균의 분포는 정규분포를 따른다

표본평균이 모집단 평균에 가까워진다

@imyngs - 무단 배포와 상업적 이용 금지입니다! 그 정도가 아니거든요... | © 2026

점추정

점 추정은 추정값이 실제 모수와 얼마나 차이가 있는지에 대한 불확실성이나 오차범위를 직접적으로 제공하지 않음

얼마나 가까운지 파악 시에 표본오차 사용안함

구간추정

신뢰구간은 모수가 포함될 가능성이 높은 구간

낮은 신뢰도는 좁은 (짧은) 신뢰구간을 만든다

비모수검정

RUN 검정 (연속성)도 포함된다

부호검정: 두관찰치의 전후를 비교하기 위해 그 크고작음을 표시하여 분포차이에 대한 가설을 검정하는 방법.

전체자료에서 중앙값을 뺐을 때 그 값이 양수인지 음수인지 검정을 수행하는 방법

표본크기가 작을수록 비모수검정이 유용하다

표본의 크기가 클수록 모수검정이 유용하다(정규분포에 가까워도 모수검정 유용)

비모수검정은 모집단에 대한 가정이 필요하지 않아 모집단의 분포가 정규분포하지 않다면(혹은 비대칭이면) 비모수검정이 효과적

숫자로 표현되지만 수량화가 불가능하다면 비모수검정이 효과적이다

회귀분석

오차: 모집단이 회귀식으로부터 얻은 예측값과 실제관측값과의 차이

@imyngs - 무단 배포와 상업적 이용 금지입니다! 그 정도가 아니거든요... | © 2026

잔차: 표본집단이 회귀식으로부터 얻은 예측값과 실제 관측값과의 차이

회귀모형 평가시 1일수록 좋은 분석

다중회귀: 2개이상의 독립(설명)변수와 하나의 종속 변수 간 선형관계

릿지회귀: 가중치의 제곱합을 최소화하는 것을 제약조건으로 추가. 가중치의 파라미터를 0에 가깝게 만들어 모형의 일반화 성능을 향상

라쏘회귀: 가중치의 절댓값의 합을 최소화하는 것을 제약조건으로 추가

데이터정규성 검증방법

히스토그램, QQPLOT, 샤피로검정, 왜도와 첨도, KOLMOGOROV-SMIRNOV

결정계수는 아니다

다중공선성 문제

다중공선성이 심하면 회귀계수의 추정이 불안정해질 수 있다 (O)

다중공선성이 존재하더라도 회귀계수의 분산은 일정하다(X)> 일정하지 않다(O)

↳ 추정이 불안정한 이유는 분산이 증가하기 때문이다

다중공선성이 존재하면

1. 중요도 낮고 상관계수 높은 변수 제거
2. 변수를 정규화 표준화 수행으로 간접적으로 감소
3. 표준오차가 증가해 회귀계수 추정이 어려워진다
4. 결정계수의 의미를 잃게 만든다

@imyngs - 무단 배포와 상업적 이용 금지입니다! 그 정도가 아니거든요... | © 2026

회귀모형의 검정

회귀모형의 통계적 유의성은 F통계량의 P-VALUE 추정된 회귀계수의 통계적 유의성은 T통계량의 P-VALUE 설명력은 R SQUARE

모형의 적합성 평가는 선형성, 독립성, 등분산성, 정규성 검토

결정계수의 통계적 유의성은 고려안함

독립변수의 P-VALUE를 확인하여 독립변수의 유의성을 파악한다

결정계수는 0~1 사이의 값을 갖는다

결정계수의 값이 클수록 회귀모형의 설명력은 높다

결정계수의 값은 SSR/SST의 값으로 계산한다

수정된 결정계수는 다중공선성에서 올 수 있는 문제를 해결하기위해 도입된 지표

다변량 분석

스피어만 상관계수는 서열(순서) 척도간 비선형적인 단조관계를 측정하는 지표

범주형에는 적용할 수 없으며, 선형관계를 측정하는 지표도 아니다

피어슨 상관계수는 두변수간 선형관계의 방향과 강도를 나타내는 지표로, 각변수에 양의 상수를 곱하거나 상수를 더하는 선형변환을 적용하더라도 상관계수의 값은 변하지 않음

@imyngs - 무단 배포와 상업적 이용 금지입니다! 그 정도가 아니거든요... | © 2026

주성분 분석(PCA)

주성분의 가중치는 자동으로 산출된다

적절한 주성분 개수를 결정하기 위해 분산활용

평균고유값 방법은 각주성분들이 갖는 고유값의 평균을 구한 뒤 평균보다 작은 고윳값을 제거하는 방법

주성분 분석은 시각화에 도움이 된다

차원축소는 비지도학습

주성분 상호관계는 항상 0이다

변수개수 만큼 주성분을 생성할 수 있다

↳(데이터개수 아닙니다)

첫번째 주성분과 두번째 주성분은 서로 가장 높은 상관을 가진다 <오답>

↳서로 상관 없다

각 주성분은 서로 선형독립이며 직교성을 만족한다 <독립(직교)>

다차원 척도법(MDS)

다차원 척도법은 거리, 유사도 기반, 차원축소, 시각화

2~3차원에 시각화해 데이터들 간의 관계를 직관적으로 이해가능(저차원공간에 배열)

다차원척도법은 데이터에 잠재해있는 패턴이나 구조를 파악하는 것이다

차원을 축소하는 과정에서 일부 거리왜곡이 발생할 수 있어, 다른 데이터와의 거리를 항상 보전하기엔 어렵다는 단점이 있다

절대적인 위치나 좌표값은 갖지 않아 절대적 위치는 파악불가(only상대적 위치관계 보존)

@imyngs - 무단 배포와 상업적 이용 금지입니다! 그 정도가 아니거든요... | © 2026

데이터가 서열척도인 경우에는 비계량적방법으로 다차원척도법 수행 가능하다

시계열 분석

시계열그래프를 통해서 정상성과 이상치 여부 모두 판단 가능하다

시계열데이터는 대부분 비정상시계열이기 때문에 정상시계열로 만든 후에 분석 수행가능

정상성

정상시계열인 경우 평균값 주변에서 변동의 폭은 대체로 일정하다

시계열의 정상성

평균은 시간에 따라 일정하게 유지된다

자기공분산을 시차에 따라 변한다

분산은 시점에 의존하지 않는다

자기상관계수는 시차에 따라 감소한다(시간이 아님!!)

불규칙하더라도 일정한 추세를 갖는다 (X)

↳ 일정함아님

시점에 따라 체계적으로 감소한다(X)

↳체계적 감쇠는 시간적추세

평균 분산은 시점에 의존하지 않는다

모수(평균 분산)는 시점에 의존하지 않는다

공분산은 시차에만 의존하고 “시점”에는 의존하지 않는다

@imyngs - 무단 배포와 상업적 이용 금지입니다! 그 정도가 아니거든요... | © 2026

평활화

지수평활법

↳과거자료가 현재자료보다 더 많은 정보를 갖고 있다는 가정하에 분석(X)

현재자료가 과거자료보다 더 많은 자료를 갖고 있다(O)

백색잡음

가우시안 백색잡음은 평균이 0이면서 분산이 일정한 정규분포를 따르는 경우

시계열 모형

차분 차수 먼저 구해서 정상성 확보한 다음 모형을 정한다

자기회귀모형

↳ 현재데이터는 이전시점 N개에 의해 설명되는 모형

백색 잡음과 과거 N개의 데이터의 선형결합으로 이루어지는 모형

현재로부터 K번째 이전 사람들은 서로 다른 가중치를 갖는 모형

부분자기함수와 자기상관함수 모두 시차가 증가함에 따라 감소하는 그래프를 가진다

상관계수 값이 클수록 과거 직전 자료들이 현재 시점에 영향을 많이 미치고 있음을 알 수 있다

분류분석

분류분석은 지도학습, 범주를 예측

@imyngs - 무단 배포와 상업적 이용 금지입니다! 그 정도가 아니거든요... | © 2026

로지스틱회귀분석의 연결함수는 로짓함수

종속변수의 확률을 로짓변환하여 설명변수와 선형결합의 형태로 모델링한다

로지스틱회귀분석은 ODDS 값에 로그를 취해 종속변수로 활용한다

범주가 3개이상인 경우 다항로지스틱 회귀분석을 통해 예측가능

회귀계수를 통해 각변수의 중요도 판단 가능

직관적 해석은 불가능

종속변수의 로짓변환은 독립변수의 선형결합이다 (O)

종속변수는 로그형태이므로 지수식으로 치환해야 확률의 변화를 확인할 수 있다

독립변수가 한단위 증가할 때 E의 회귀계수승만큼 오즈값이 증가한다

KNN

사전학습 필요없음

K값이 작을수록 이상치에 민감하게 반응해 과적합 발생

K값 커질수록 모델이 너무 단순해지는 과소적합 발생

거리계산을 위해 특정값의 정규화가 필요하다

나이브베이즈 분류

베이즈 정리

↳과거경험과 현재증거를 기반으로 미래를 측정, 귀납적 추론임

@imyngs - 무단 배포와 상업적 이용 금지입니다! 그 정도가 아니거든요... | © 2026

의사결정나무

이상값에 민감하지 않다

지도학습이다

의사결정나무는 지도학습이며 상향/하향식 접근과는 관계가 없다

반응변수가 연속형일때, 100%로 정확한 모형 만들 수 있다

↳항상은 아니다

반응변수가 범주형일때, 노드의 순수도가 감소하는 방향으로 구성된다 (X)

↳불순도가 감소, 순수도는 증가합니다

의사결정나무는 구조가 단순하며 해석이 용이한 장점이 있다

목표변수의 유형(이산형, 연속형)에 따라 적용되는 알고리즘은 다르다

정지규칙, 가지치기등을 통해 분류나무를 최적화할 수 있다

지니지수는 불순도를 측정하는 지표로 단일원소로(완전순수) 구성될때 값은 0이다

엔트로피지수는 불확실성(불순도)를 측정하기 위한 지표다

엔트로피는 분류분석 수행 뒤 구축된 모형성과 평가 못함

앙상블

지도학습이다

분류 정확도의 향상

각분류기 간에 상호연관성이 높으면 정확도는 떨어진다

모형의 투명성이 낮으므로 원인분석에 활용하기엔 적합하지 않다

전체적으로 이상값에 민감하지 않은 장점이 있다

↳ (배깅, 부스팅, 랜덤포레스트 모두 이상값에 민감하지 않다)

앙상블은 여러 개의 예측모형을 조합하는 기법으로 하나의 분류기에서 오는 낮은 신뢰성

@imyngs - 무단 배포와 상업적 이용 금지입니다! 그 정도가 아니거든요... | © 2026

을 높이는 것이 주목적이다

배깅은 일반적으로 단일모델보다 정확도가 향상되는 경향이 있지만 “항상”은 아니다

배깅은 과대적합 방지한다

붓스트랩은 모집단의 크기가 동일한 크기를 갖는 표본집단으로 기존의 모집단으로부터 복원 추출에 의해 생성된 표본집단이다

블랙박스 모델은 배깅보다 더 많은 무작위성이 있다

부스팅은 반복학습이 많거나 모델의 복잡도가 높은 경우 과적합 위험이 커진다

인공신경망 (요즘엔 이거 중요해요★)

단층 퍼셉트론은 선형회귀와 유사하다 (퍼셉트론 자체가 선형회귀)

은닉층이 없는 신경망에 시그모이드 함수를 활성함수로 적용하면 로지스틱 회귀와 유사하다

렐루함수를 사용하면 기울기 소실 문제를 완화할 수 있다

은닉층은 여러 개가 될 수 있다

출력층의 노드수는 출력범주의 개수와 동일해야한다

입력층 노드의 수는 입력차원의 수와 동일해야한다

은닉층 노드 수가 많다고 모형성능이 항상 향상되는건 아니다. (모형의 표현력이 증가)

활성함수의 선택은 분석가가 데이터 특성을 고려해 직접 설정한다

입력 → (은닉) → 출력으로 입출력은 필수, 은닉층은 0개 이상

설명력 있는 가중치를 선출 못한다

모든 은닉층의 노드의 수는 다를 수 있다 (O)

은닉층이 없는 인공신경망을 선형회귀모형과 동일한 특성을 갖는다

XOR 문제는 비선형

@imyngs - 무단 배포와 상업적 이용 금지입니다! 그 정도가 아니거든요... | © 2026

인공신경망 구조에서 각 노드의 입력된 신호의 가중합 처리, 뉴런의 출력여부와 전력강도를 결정하는 비선형변환함수는 “활성화”함수

가중치를 부여하는 목적은 “입력신호의 강도조절”

은닉층이 많으면 과적합

은닉층이 적으면 과소 적합

포화문제: 역전파에 의한 가중치 수정 중 절댓값이 커져 과소적합 발생 현상

시그모이드 0~1

Tanh -1~1 중심값 0

Relu 입력값과 0 중에서

Sign -1 or 1

Step 0 or 1

소프트맥스 함수는 출력이 다범주

소프트맥스 함수= 목표변수가 범주형인 경우 활용가능한 활성화 함수, 종속변수가 다범주의 경우에도 적용

Mse: 회귀 모델 → 오차에 제곱을 적용해 이상값에 민감하다. 이상값 처리가 중요하다

@imyngs - 무단 배포와 상업적 이용 금지입니다! 그 정도가 아니거든요... | © 2026

분류모델 평가지표

오분류표는 분류분석의 성능을 판단하기 위해 활용한다

↳(예측/실제 방향 바꿔서 출제를 많이 합니다! 표 제대로 외우기!!)

평가지표

정밀도: 예측값 True 중 올바르게 True를 찾아낸 비율

재현율(민감도): 실제 True 중 올바르게 True를 찾아낸 자료

특이도: 실제 False 중 올바르게 False 찾아낸 자료

정확도: 전체 관측치 중 올바르게 예측한 비율

F-1 Score: 정밀도 재현율의 조화평균 값

일반 벤다이어그램은 분류모형 평가를 위해 사용하는 방법아님

↳ 집합표현 그래프임

군집분석

군집분석은 종속변수 필요없다

군집분석은 이상치에 민감한 특성이 있다

비지도 학습이다

뚜렷한 목적없이 데이터 탐색을 위해 활용될 수 있다는 장점이 있다 (비목적성)

덴드로그램을 최장연결법으로 수행하면 재분석해도 결과 안달라진다, 거리, 유사도 기준으로 병합한다. 군집의 크기 기준 아님. (직접적으로 친밀도 관계성 측정 안함)

혼합분포군집분석은 사전에 군집개수 정함

↳ 군집의 크기가 작으면 군집의 추정이 어렵다. 특정분포가 여러 개의 확률분포의 가중합으로 표현된다

@imyngs - 무단 배포와 상업적 이용 금지입니다! 그 정도가 아니거든요... | © 2026

혼합분포군집분석 = Expectation Maximization 알고리즘 사용한다 =EM알고리즘

↳ 모수 및 가중치 추정하는 군집분석 (확률모델의 최대 가능도)

혼합분포군집분석은 복잡한 형태를 가진 분포의 경우 선형결합된 여러 개의 확률분포로 설명가능하다. 군집을 몇 개의 모수로 표현할 수 있으며, 각각의 군집은 확률분포로 나타내어진다. 모수 추정에서 데이터가 커지면 군집 수행을 위한 반복횟수가 커진다

유클리디안 거리: 두 데이터 사이의 최단거리를 측정

맨하튼거리 = 시가거리

범주형 변수에 단순일치 계수도 포함

↳코사인유사도는 두 벡터간의 각도를 이용해 유사도를 측정하는 방법으로 주로 문서(텍스트)의 유사도를 측정하기 위한 지표 크기가 아닌 방향성 (완전일치 1, 다른방향 -1)

계층적 군집형성 방법에는 병합적 방법과 분할적 방법이 있다

계층적군집방법은 군집의수를 미리 지정하지 않으며 탐색적 기법에 정확한 군집방법이다

최장연결법은 새로 생성되는 군집과 기존 데이터의 거리 측정 시 가장 먼 데이터를 군집과 기존 데이터의 거리로 정의한다

K평균 군집화

최적의 군집이 되기 위해선 구형 또는 볼록한 형태

군집개수 K를 결정할 때 활용가능 그래프 = 집단 내 제곱합 그래프(wcss)

각 데이터는 하나의 군집에만 할당된다 (하나의 데이터가 동시에 여러군집에 속할 수 없다)

탐욕 알고리즘으로 최적의 군집 보장 못함

초기 중심점은 무작위로 선택한다 / K-medoids: 단점보완위해 설계됐으나 수행속도느림

@imyngs - 무단 배포와 상업적 이용 금지입니다! 그 정도가 아니거든요... | © 2026

기타 비계층적 군집분석

EM 알고리즘: 확률모델의 최대가능도, 혼합분포군집

자기조직화지도: 차원축소 + 인공신경망 + 군집화

자기조직화지도는 비지도학습

ㄴ최적의 초기학습률 및 가중치의 결정이 어렵다는 단점이 있다

은닉층 없음

SOM은 입력데이터와 가까운 뉴런값은 더 가깝게 먼 데이터는 더 멀게 가중치 조정하며 군집을 형성하는 비지도 학습 방법이다

각 노드에는 항상 동일한 데이터가 할당된다? (X)

ㄴ경쟁학습을 하기 때문에 달라지므로 동일하지 않습니다, 일정하지도 않음

경쟁층에 도달하여도 iteration이 진행됨에 따라 경쟁층의 다른 노드로 이동 가능합니다

입력층과 경쟁층의 거리를 보존할 수 있습니다

역전파 알고리즘을 사용하지 않아 단순하고 계산속도가 빠르다

고차원 데이터를 저차원 데이터로 시각화합니다

데이터가 유사성 구조 파악과 군집하는데 효과적입니다

연관분석

비지도 학습입니다

지나친 품목 세분화는 의미없는 결과를 도출할 수 있으므로 적정수준의 세분화가 필요합니다

<단점보완이지 장점이 아닙니다!!!>

ㄴ 비슷한 데이터들에 대해 하나의 집단으로 묶어서 수행할 경우 계산량이 기하급수적으로 증가하는 것을 방지할 수 있습니다

@imyngs - 무단 배포와 상업적 이용 금지입니다! 그 정도가 아니거든요... | © 2026

연관분석은 순차패턴도 if ~ then ~형태로 해석됩니다

비목적성으로 명확한 분석목적이나 방향 없이도 활용가능합니다

데이터 변환 없이 사용 가능합니다

목적 변수가 없습니다 (데이터 탐색에 용이)

품목수 증가시 계산량 기하급수적 증가로 오랜시간이 필요합니다

분석의 계산량은 많지만 계산 복잡도는 낮습니다

지지도 신뢰도 둘 중에서 더 중요한거 고를 수 없습니다

연관규칙 (A→B) 지지도와 (B→A)는 같습니다

연관분석의 측도

두 품목이 독립인 경우 향상도는 1이 되고, 이때 지지도와 신뢰도는 같은 값입니다

지지도가 1(100%)인 경우 해당 품목은 모든 거래에 포함되는 것을 의미합니다

각 품목의 지지도는 개별적으로 계산되며 중복발생이 가능합니다

모든 지지도의 합은 1을 초과할 수 있습니다

향상도 값은 확률값을 확률값으로 나눈 것으로 항상 0또는 양수의 값을 갖습니다

연관규칙 (A→B)에서 향상도가 1보다 크다는 것은 B를 구매할 확률보다 A를 구매한 뒤 b를 구매할 확률이 더 크다는 것을 의미합니다

향상도=1 일땐 두 품목이 서로 독립으로 서로 상관없습니다

빈발항목 도출 알고리즘

APRIORI 알고리즘:

계산량이 많아지면 속도 느려지고, 빠른 속도 보유하지 않습니다
거래 발생하지 않은 품목대상으로는 규칙 탐색이 불가능합니다

@imyngs - 무단 배포와 상업적 이용 금지입니다! 그 정도가 아니거든요... | © 2026